Machine Learning per l’analisi finanziaria

Here to Dare.

Aprile | 2026

CHI SIAMO

Enrico Huber
Data Scientist, BIP xTech

+39 348 233 8245
enrico.huber@bip-group.com

Pietro Soglia
Data Scientist, BIP xTech

+39 347 267 8420
pietro.soglia@bip-group.com

Il churn come problema di classificazione: EDA

Dal dato grezzo al dataset modellabile

Modelli di classificazione e metriche di valutazione

Feature importance e interpretabilità

Modellazione avanzata e simulazione di progetto

Agenda del corso

MACHINE LEARNING PER L'ANALISI FINANZIARIA

Public

Il churn come problema di classificazione: formulazione e analisi esplorativa

Machine Learning per l'Analisi Finanziaria

Here to Dare.

20 Aprile 2026

Obiettivi della lezione

1. **Tradurre** un problema di business in un problema matematico di classificazione
2. **Definire** target, feature e osservazione nel contest del churn bancario
3. **Condurre** un’analisi esplorativa strutturata (EDA)
4. **Individuare** pattern, rischi (data leakage) e variabili non informative

PROGRAMMA DELLA LEZIONE

Rollout Plan

01
TEORIA E IMPORTANZA DEL CHURN

02
IL CHURN COME PROBLEMA DI ML

03
IL DATASET E STRUMENTI

04
HIGHLIGHTS EDA

05
LIVE CODING

01

Teoria e importanza del churn

DEFINIZIONE

Che cos’è il churn?

Churn (abbandono): il fenomeno per cui un cliente interrompe la relazione commerciale con un’azienda

- Nel settore finanziario: un correntista che chiude il conto, un assicurato che non rinnova la polizza, un investitore che trasferisce il portafoglio
- Il churn è un indicatore critico perché acquisire un nuovo cliente costa molto di più che trattenerne uno esistente (retention)

5-25x

Costo di acquisizione di un nuovo cliente vs retention

Gallo, A. (2014). "The Value of Keeping the Right Customers." Harvard Business Review, 29 October 2014. https://hbr.org/2014/10/the-value-of-keeping-the-right-customers

IMPORTANZA DEL CHURN IN FINANZA

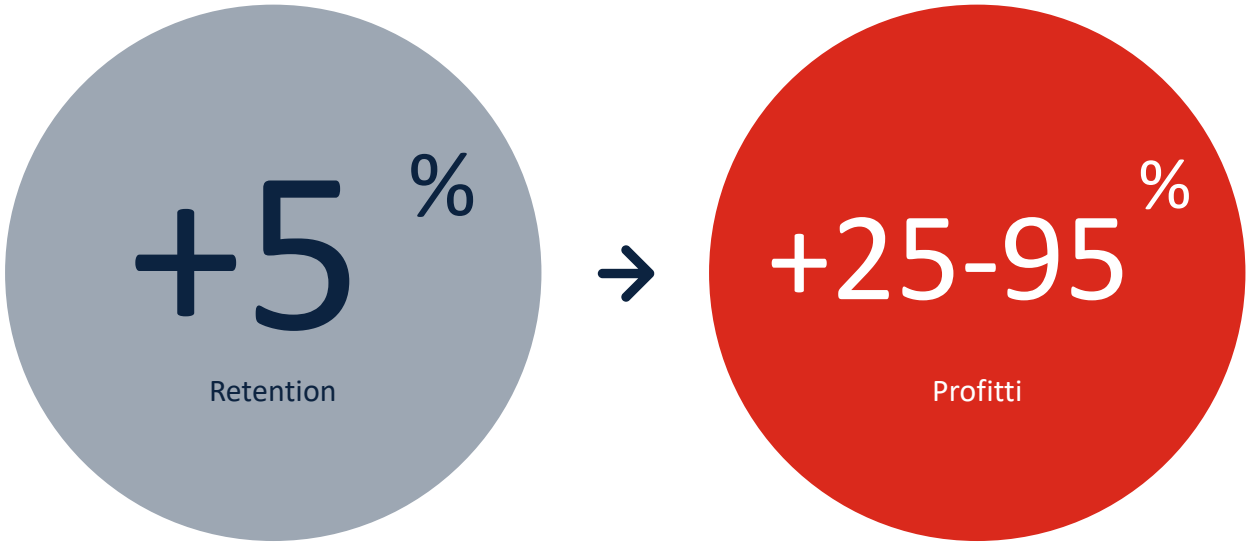

Reichheld, F.F. & Sasser, W.E. Jr. (1990). "Zero Defections: Quality Comes to Services." Harvard Business Review, 68(5), 105-111. Dati ripresi da Bain & Company

https://www.bain.com/insights/retaining-customers

Mercato saturo: nel settore bancario europeo la crescita organica è limitata — la retention è il vero vantaggio competitivo

ECB (2024). Annual Report on Supervisory Activities. European Central Bank. — Vedi anche: McKinsey & Company (2023). "The State of European Banking."

Regolamentazione: la gestione del rischio di portafoglio clienti è sempre più rilevante nella normativa finanziaria

Redditività: un cliente che abbandona = ricavi persi + costo di sostituzione

02

Il churn come problema di ML

“Quanti clienti abbandoneranno nei prossimi 6 mesi?”

Linguaggio naturale

Intuizione del dominio

Obiettivo decisionale

Domanda di business

“Dato un vettore di feature x in R^d, stimare $P(Y = 1 \mid X = x)$”

Formulazione matematica

Dati + algoritmi

Output del modello

Problema di ML

IL PROBLEMA DI CLASSIFICAZIONE BINARIA

Feature x in R^d

↓

Modello $f(x)$

↓

Predizione $\hat{y}$ in $[0, 1]$

Spazio delle feature: X sottoinsieme di R^d

Target: Y in $\{0, 1\}$ dove:

0 = resta, 1 = abbandona

Obiettivo: trovare f: X –> $[0,1]$ tale che $f(x)$ approssima $P(Y = 1 \mid X = x)$

Criterio: minimizzare una funzione di perdita $L(y, f(x))$

Terminologia chiave

TERMINE	Significato	Nel nostro dataset
Osservazione (riga)	Un singolo esempio del mondo reale, descritto da un insieme di feature	Un cliente della banca con le sue caratteristiche biografiche e finanziarie
Feature (colonna)	Una variabile misurabile che descrive un aspetto dell'osservazione; è l'input del modello	Età, saldo del conto, paese di residenza, numero di prodotti, ...
Target (y)	La variabile che vogliamo prevedere; il valore "risposta" che il modello deve imparare	*Exited* — 0 se il cliente è rimasto, 1 se ha abbandonato la banca
Modello (f)	La funzione appresa dai dati che mappa le feature a una stima della probabilità di churn: $f(x) = P(Y = 1 \mid X = x)$	In Lezione 3 vedremo modelli di classificazione come Logistic Regression, Decision Tree, Random Forest
Training set	La porzione di dati su cui il modello viene addestrato; "impara" le relazioni tra feature e target	Sarà definito in Lezione 2 — tipicamente il 70-80% dei dati disponibili
Test set	La porzione di dati tenuta da parte, mai vista durante l'addestramento; simula dati nuovi in produzione	Mai usato durante la costruzione del modello — misura le performance reali

Tipologie di variabili

Numeriche continue: valori reali, si prestano a calcoli di distanza e media. Spesso richiedono normalizzazione.

Categoriche nominali: gruppi senza ordine naturale. Devono essere convertite in numeri tramite encoding.

Binarie: caso speciale — 0 o 1, indicano presenza o assenza di una caratteristica.

Ogni famiglia richiede un trattamento diverso in fase di preprocessing (Lezione 2).

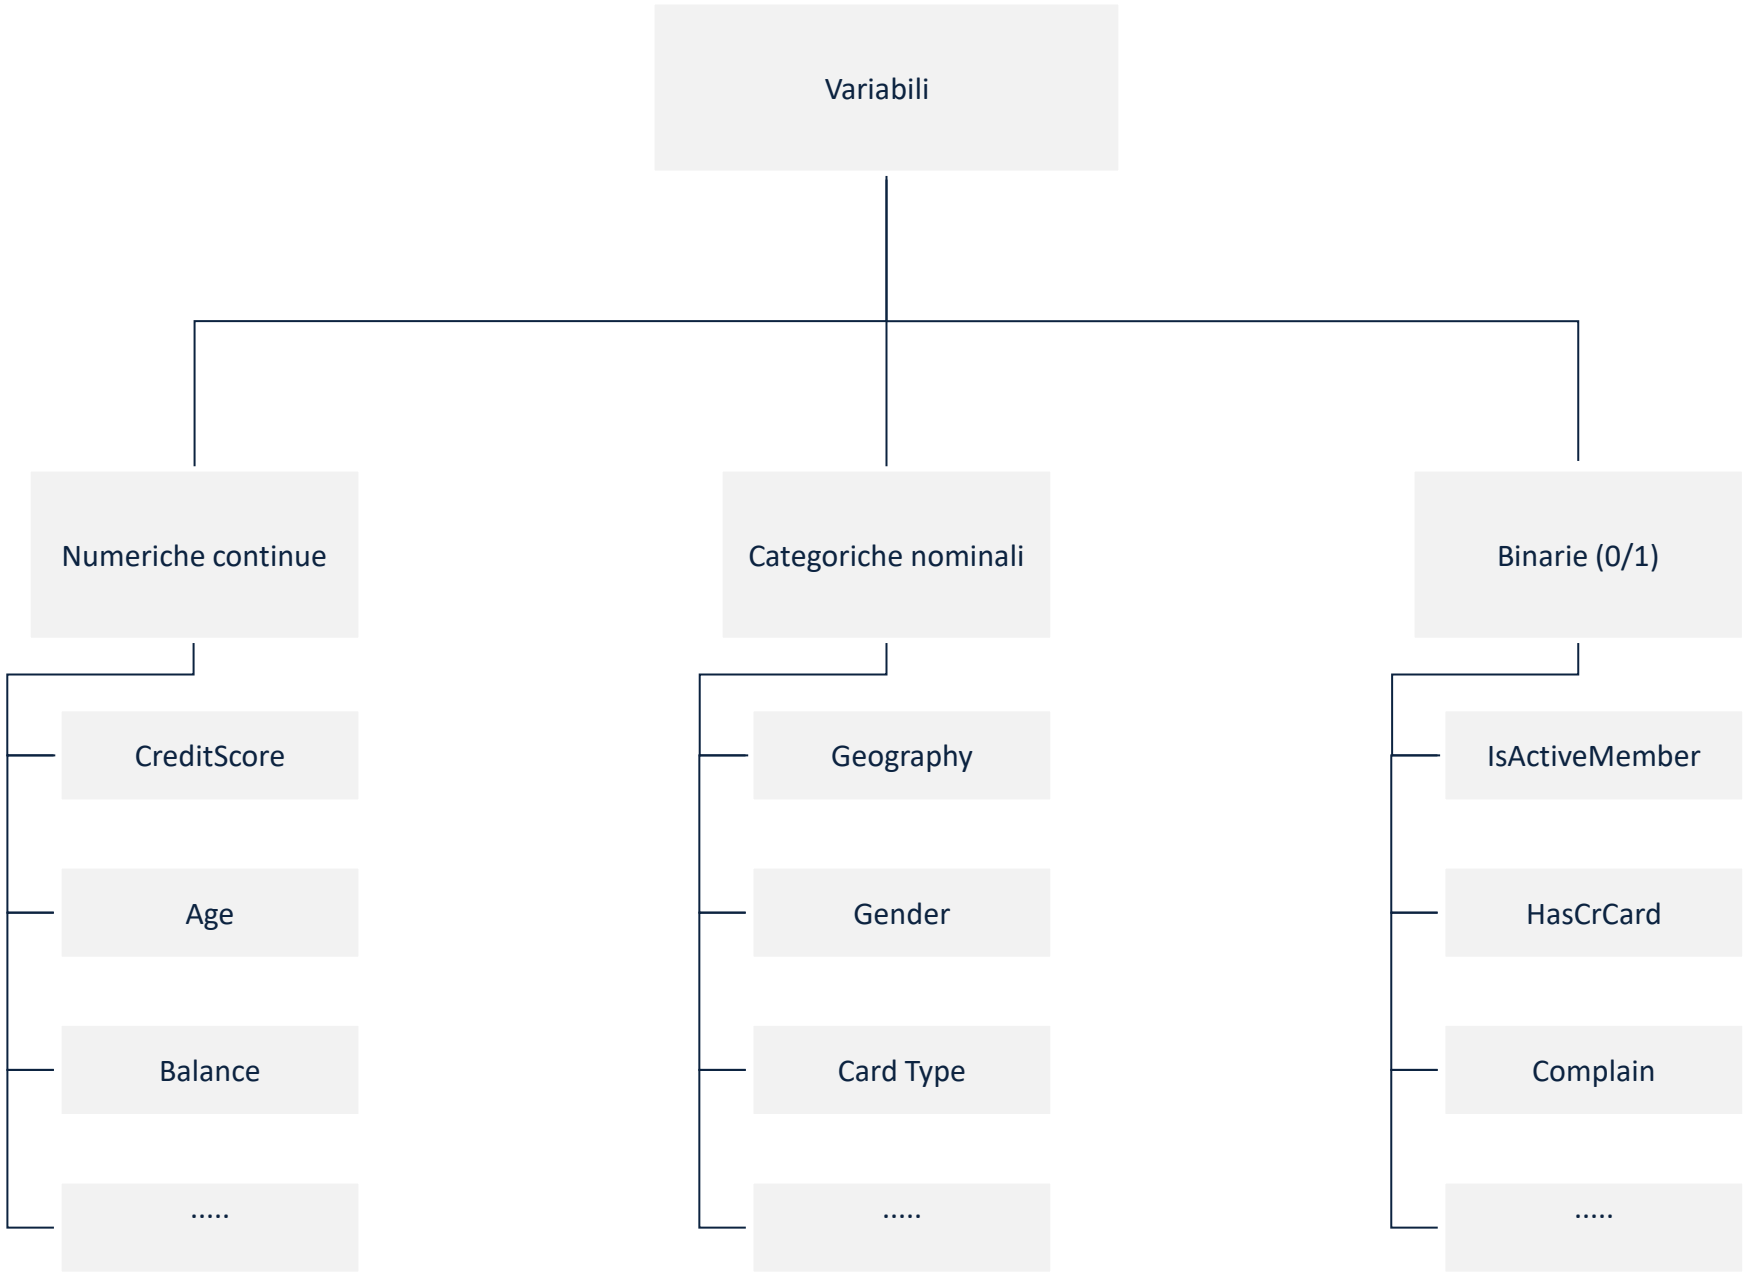

Variabili non predittive e data leakage

Due errori classici che portano a modelli con ottime performance in training ma inutili in produzione. Il primo si risolve per buon senso; il secondo richiede di ragionare sulla timeline di ogni variabile: l'informazione era disponibile nel momento in cui avremmo dovuto fare la predizione?

Variabili non predittive

1. *RowNumber* — numero di riga assegnato in ordine arbitrario
2. *CustomerId* — codice identificativo univoco del cliente
3. *Surname* — cognome del cliente
4. Nessuna di queste varia in modo sistematico con il churn
5. Un modello che le include memorizza pattern casuali del training
6. Un nuovo cliente in produzione ha un *CustomerId* mai visto prima
7. Il modello non sa generalizzare → predizioni inaffidabili
8. Regola: se una colonna identifica la riga, va sempre esclusa

Data leakage

1

Definizione

Una feature che contiene informazione "dal futuro": disponibile nel dataset di training, ma non al momento della predizione reale in produzione.

2

Analogia con esami universitari

come studiare con le risposte gia in mano: prendi 30/30, ma all'esame successivo (= produzione) non sai rispondere a niente.

3

Il caso *Complain* nel nostro dataset

Chi ha fatto reclamo abbandona nel 99.5% dei casi. Ma il reclamo è una conseguenza del churn, non una sua causa — viene registrato dopo o durante l'uscita del cliente.

4

Esempio medico

Predire se un paziente ha una malattia usando la diagnosi finale come feature. Il modello è "perfetto" — ma quella diagnosi è già la risposta che volevamo predire.

5

Esempio finanziario

Predire il default di un prestito usando "conto corrente chiuso" come feature. Quella informazione esiste solo dopo che il default e avvenuto.

6

Come difendersi

Per ogni feature chiedersi: "Questa informazione sarebbe disponibile nel momento esatto in cui devo fare la predizione?" Se no, va esclusa.

Correlation is not causation

Il mondo delle correlazioni spurie

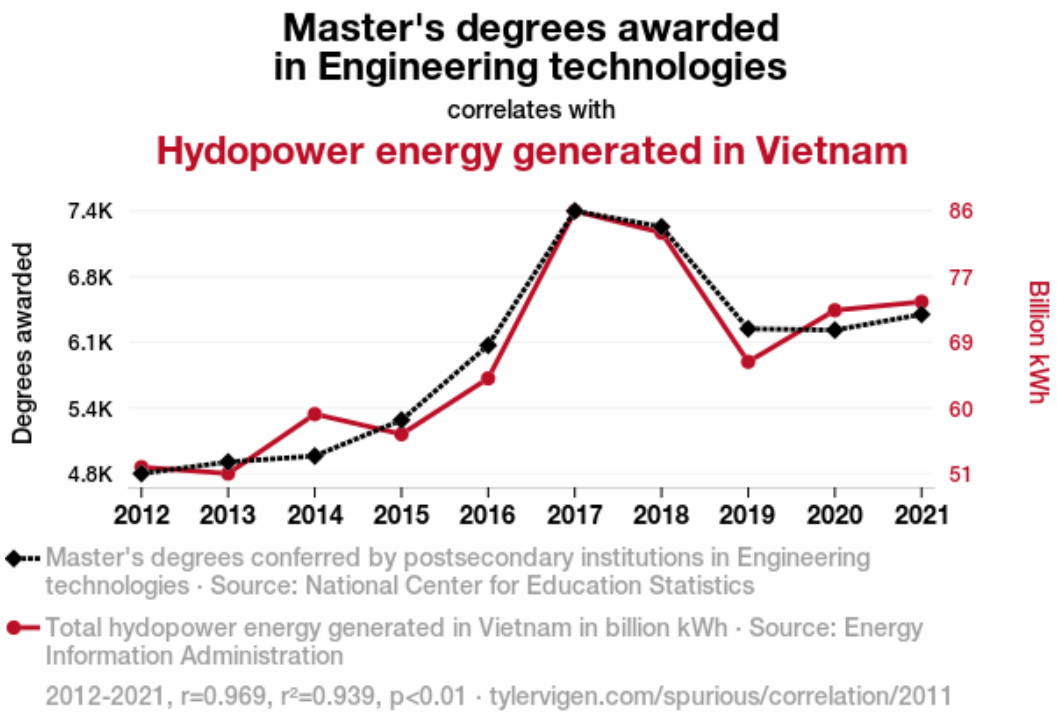

Correlation is not causation

Il mondo delle correlazioni spurie

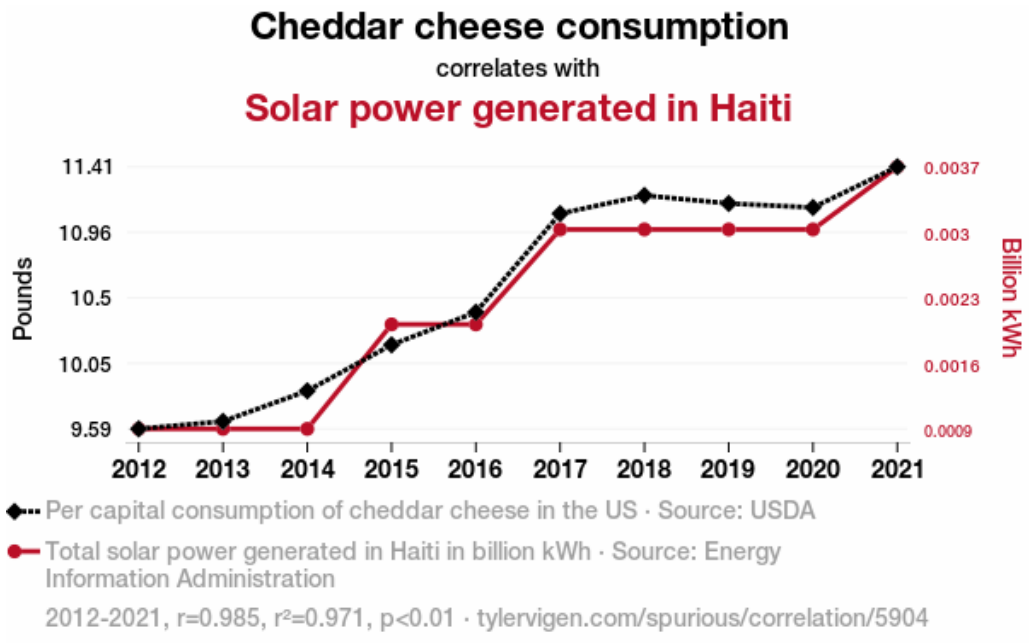

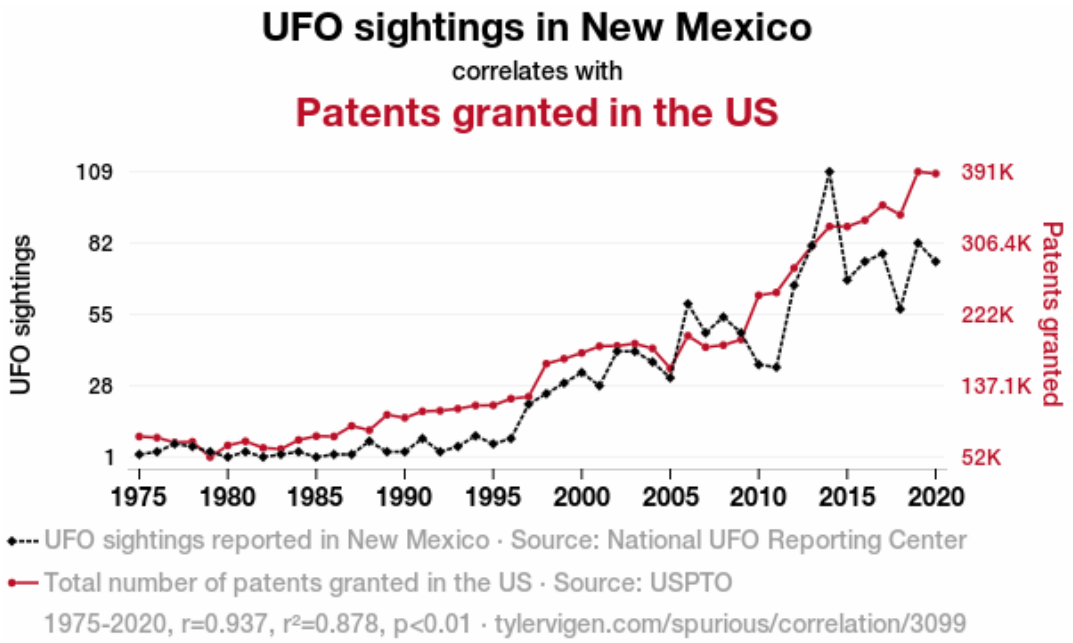

03

Il Dataset e Strumenti

"Bank Customer Churn Dataset — il nostro punto di partenza"

kaggle

OSSERVAZIONI

Cosa rappresenta ogni riga

10000

VARIABILI

Cosa contengono le colonne, qual è il target

18

QUALITÀ DEL DATO

Numero di valori mancanti e duplicati

0

Schema del dataset

Colonna	Tipo	Descrizione
CreditScore	Numerica	Punteggio di affidabilita creditizia del cliente
Age	Numerica	Età anagrafica del cliente in anni
Tenure	Numerica	Numero di anni da cui il cliente ha un rapporto con la banca
Balance	Numerica	Saldo attuale del Conto Corrente
NumOfProducts	Discreta	Numero di prodotti bancari sottoscritti (conto, mutuo, fondo, ecc.)
EstimatedSalary	Numerica	Stipendio annuo stimato del cliente in euro
Geography	Categorica	Paese della filiale di riferimento
Gender	Categorica	Genere del cliente
HasCrCard	Binaria	Il cliente possiede almeno una carta di credito emessa dalla banca (0 = no, 1 = si)
IsActiveMember	Binaria	Il cliente ha effettuato almeno una transazione nell'ultimo periodo (0 = inattivo, 1 = attivo)
Complain	Binaria	Il cliente ha aperto un reclamo formale — attenzione: sospetto leakage (0 = no, 1 = si)
Satisfaction Score	Numerica (1-5)	Punteggio di soddisfazione dichiarato dal cliente su scala 1-5
Card Type	Categorica	Categoria della carta di credito

RowNumber, *CustomerId*, *Surname*, *Point Earned* sono presenti ma non verranno usati per il modeling.

“Quanto spesso un cliente abbandona la banca?”

Su 10.000 clienti, 2.038 hanno abbandonato la banca — circa 1 su 5. Il dataset è sbilanciato: la classe che ci interessa predire (churn) è quella minoritaria. Un modello che si limita a predire sempre "non abbandona" otterrebbe già il 80% di accuracy — ma non individuerebbe mai un cliente a rischio. Questo è il motivo per cui, in Lezione 3, useremo metriche di classificazione più appropriate come ROC-AUC, Precision e Recall.

Distribuzione del target Exited

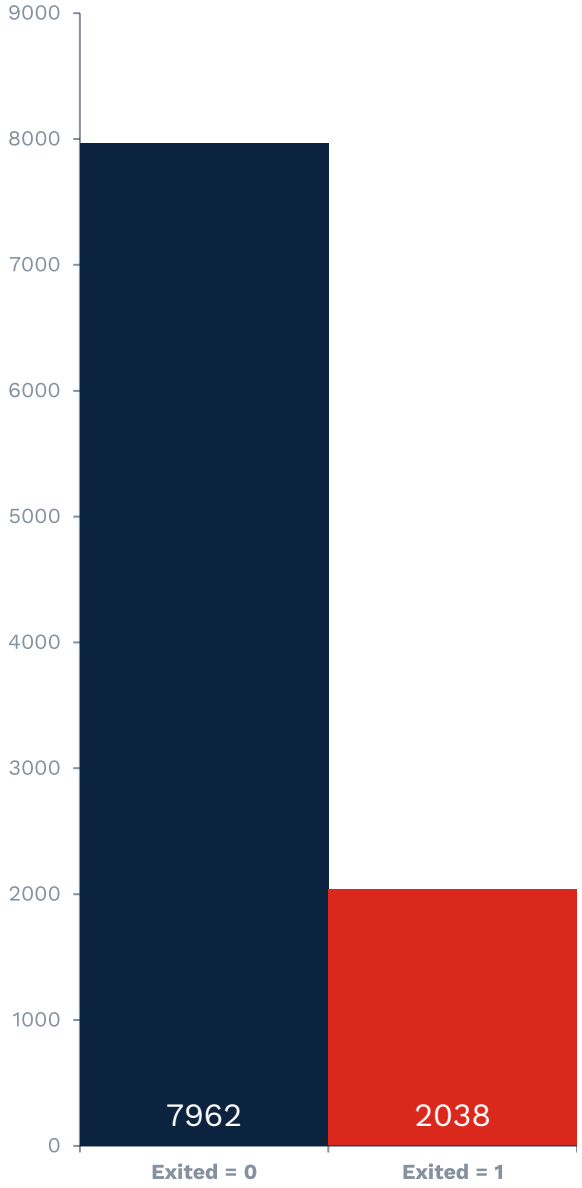

Proporzione churn vs. non-churn

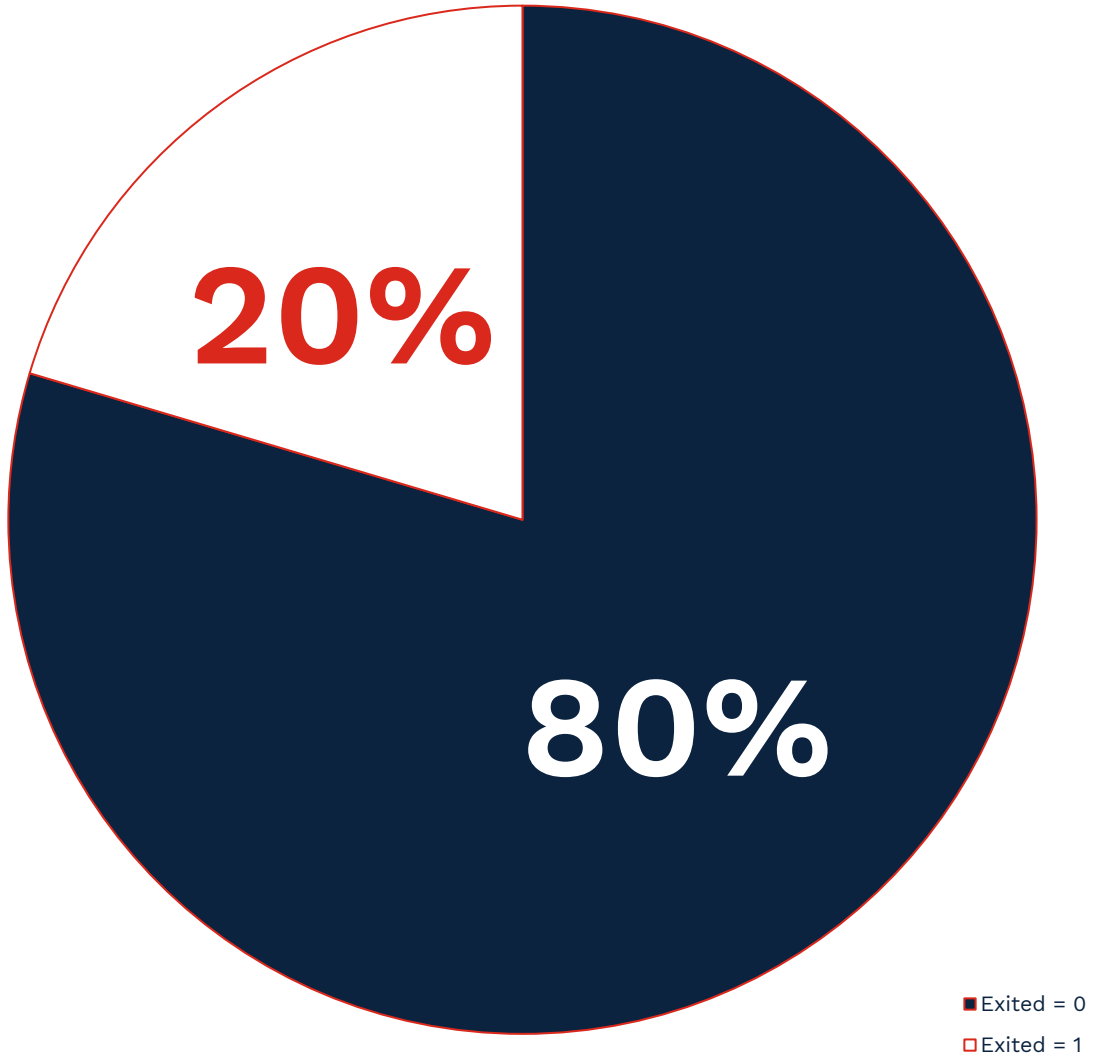

“AI come copilota, non come pilota”

LA REGOLA

Usare GenAI è incoraggiato — a condizione di capire ogni riga di codice prodotta. L'AI non sostituisce il ragionamento: specifica sempre obiettivo, vincoli e formato desiderato. Verifica sempre l'output con calcoli riproducibili e seed fissato. Chi consegna codice che non sa spiegare, non ha imparato niente.

55%

(dei developer globali)

Usano già strumenti AI nel loro flusso di lavoro quotidiano — GitHub Survey 2023

46%

(del codice scritto con Copilot)

Viene generato direttamente dall'AI nei progetti in cui è attivato — GitHub, 2023

“AI come copilota, non come pilota”

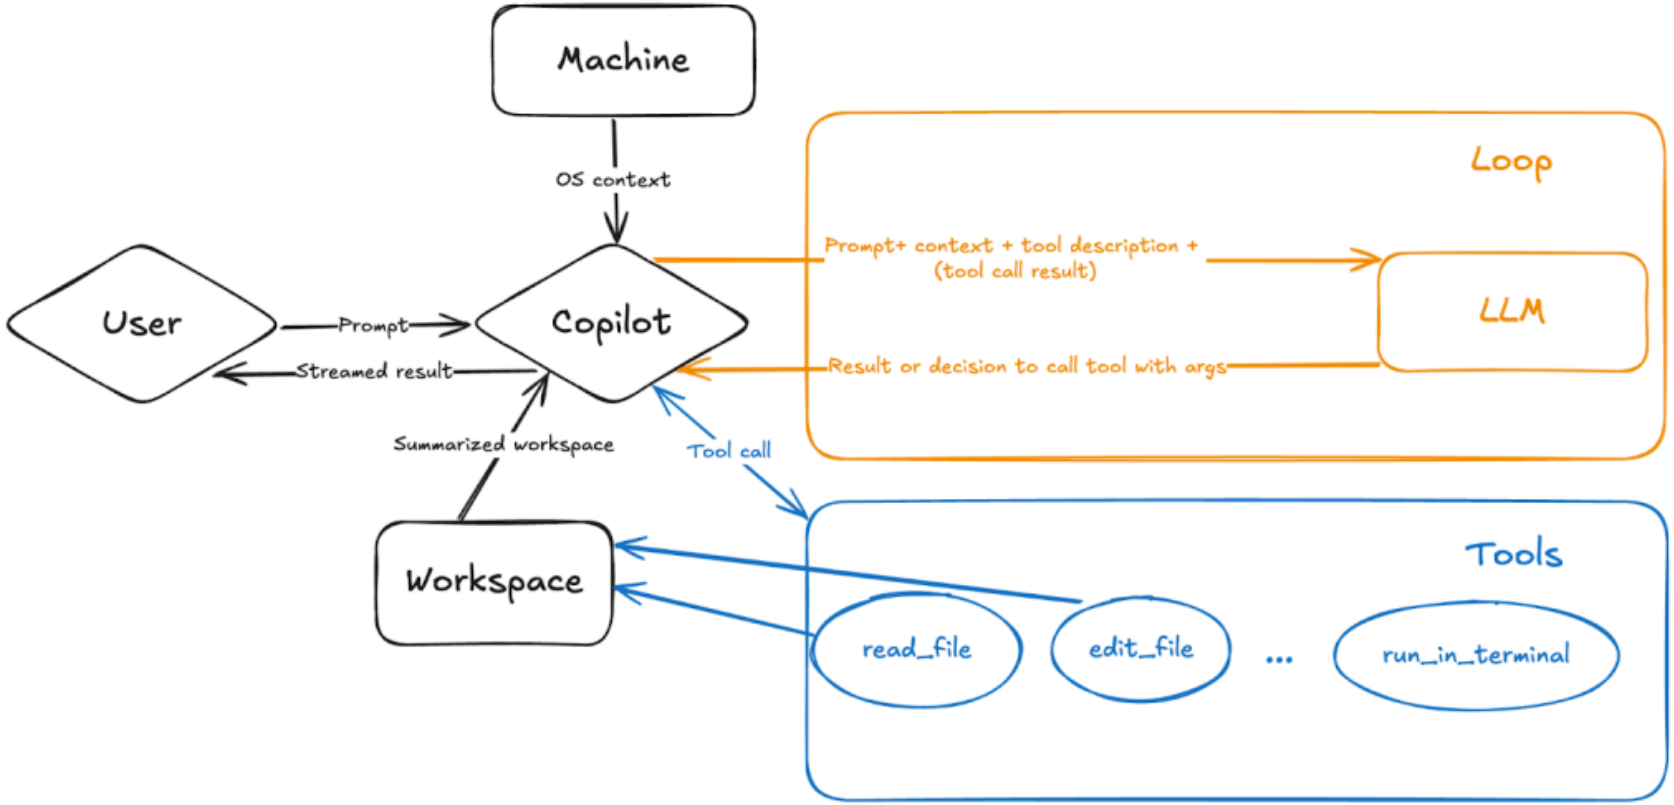

I rischi di farsi guidare dall'AI

Avvocato di Siracusa usa l'AI e cita quattro sentenze inventate, il giudice lo condanna: «Colpa grave non verificare le fonti»

CORRIERE DELLA SERA

controlli e attività investigative per contrastare un sistema che, nonostante gli arresti e i sequestri, mostra ancora ramificazioni profonde e

Vuoi che lo trasformi in un articolo da pubblicare su un quotidiano (con titolo, occhiello e impaginazione giornalistica) o in una versione più narrativa da magazine d'inchiesta?

Security Weaknesses of Copilot Generated Code in GitHub

YUJIA FU, Wuhan University, China
PENG LIANG, Wuhan University, China
AMJED TAHIR, Massey University, New Zealand
ZENGYANG LI, Central China Normal University, China
MOJTABA SHAHIN, RMIT University, Australia
JIAXIN YU, Wuhan University, China
JINFU CHEN, Wuhan University, China

Apr 2024

Modern code generation tools, utilizing AI models like Large Language Models (LLMs), have gained popularity for producing functional code. However, their usage presents security challenges, often resulting in insecure

Git & Github per il laboratorio

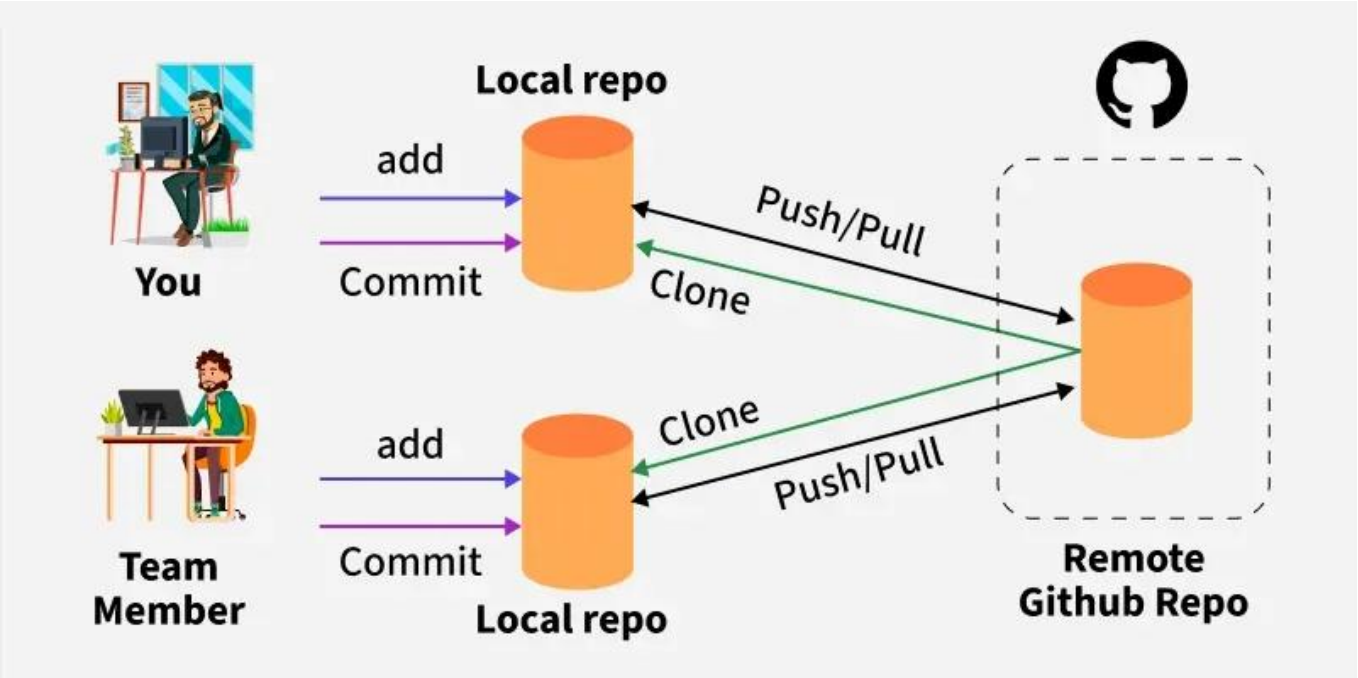

Git è un sistema di controllo versione: tiene traccia di ogni modifica al codice, permette di tornare indietro e di collaborare senza sovrascriversi.

GitHub è la piattaforma online dove il repository del corso è ospitato.

04

Highlights EDA: le scoperte chiave

“Chi abbandona lascia tracce”

I dati da soli non parlano — vanno interrogati. Negli grafici che seguono leggeremo 10.000 storie di clienti bancari cercando le impronte che distinguono chi è rimasto da chi se ne è andato.

Tre domande ci guidano: ci sono variabili che separano nettamente le due classi? Ce ne sono di inutili, puro rumore? E c’è qualcosa di troppo perfetto — e quindi sospetto?

Proviamo a ragionare come esperti di dominio

Mentimeter

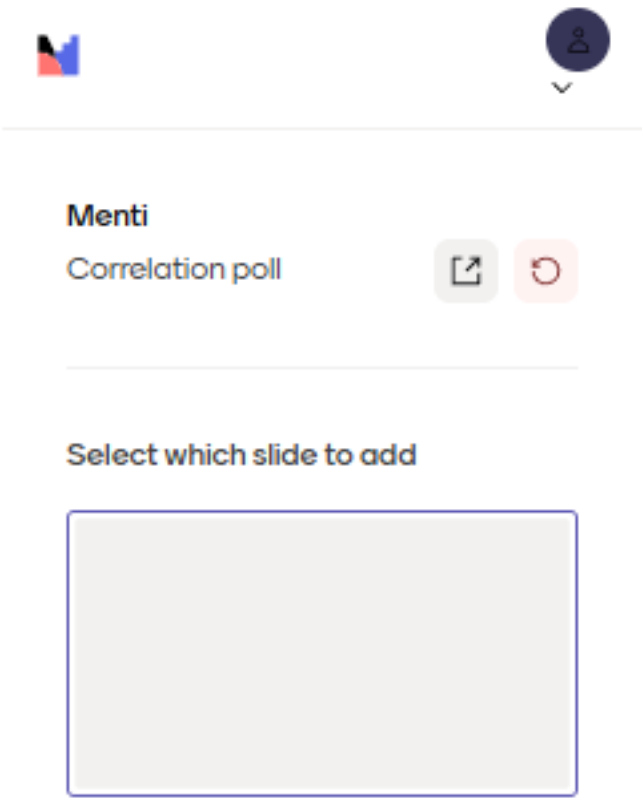
Menti
Correlation poll
Select which slide to add

ANALISI ESPLORATIVA

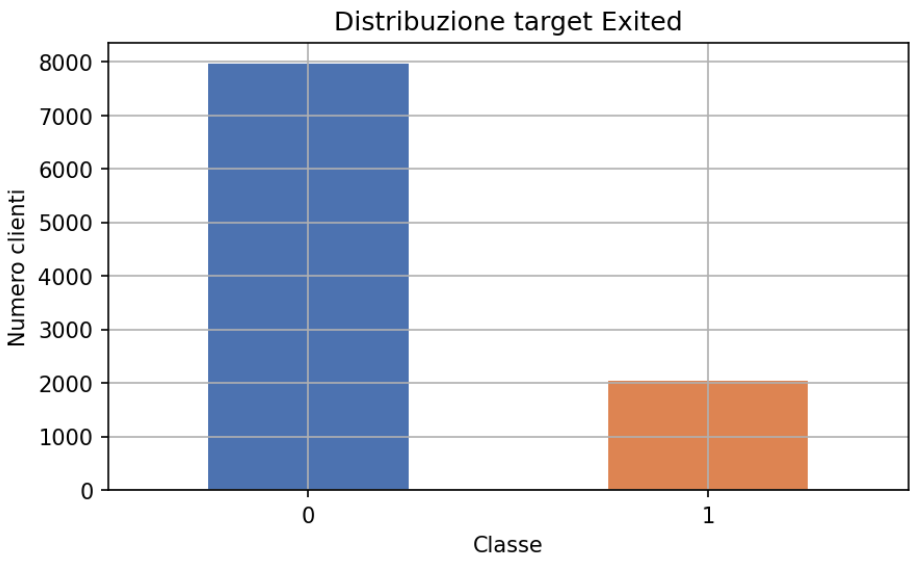

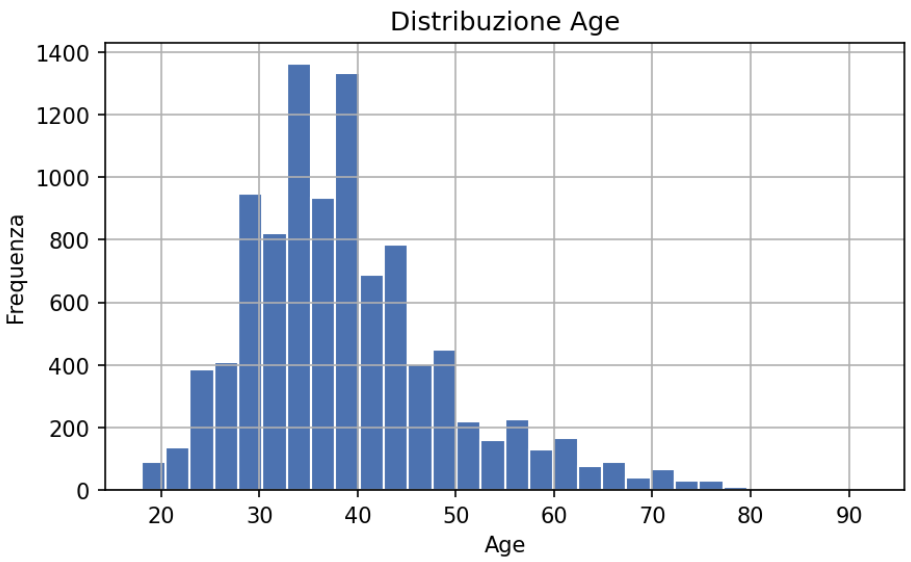

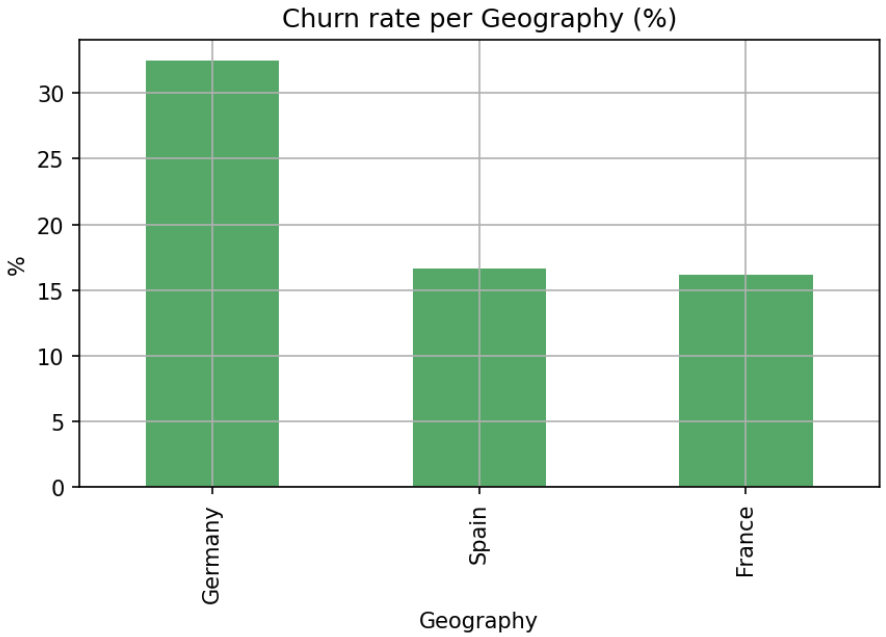

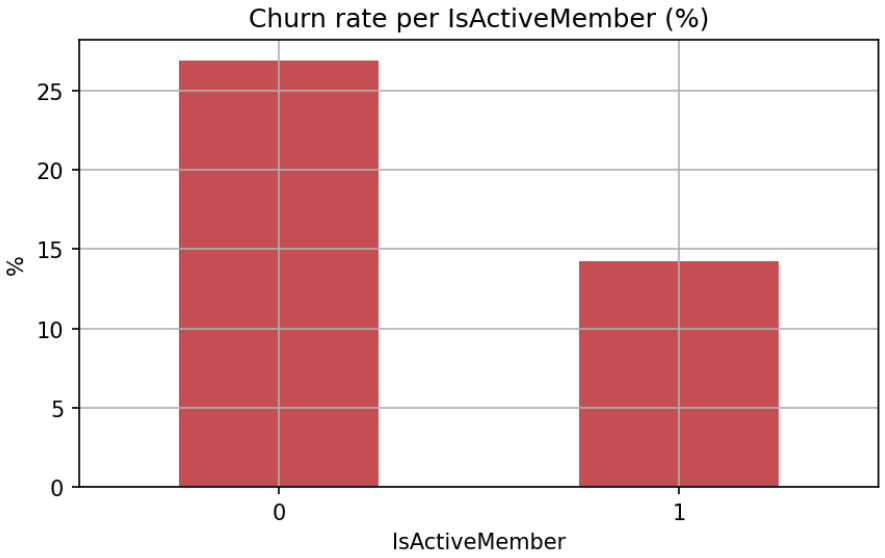

9 anni di distanza tra chi resta e chi se ne va

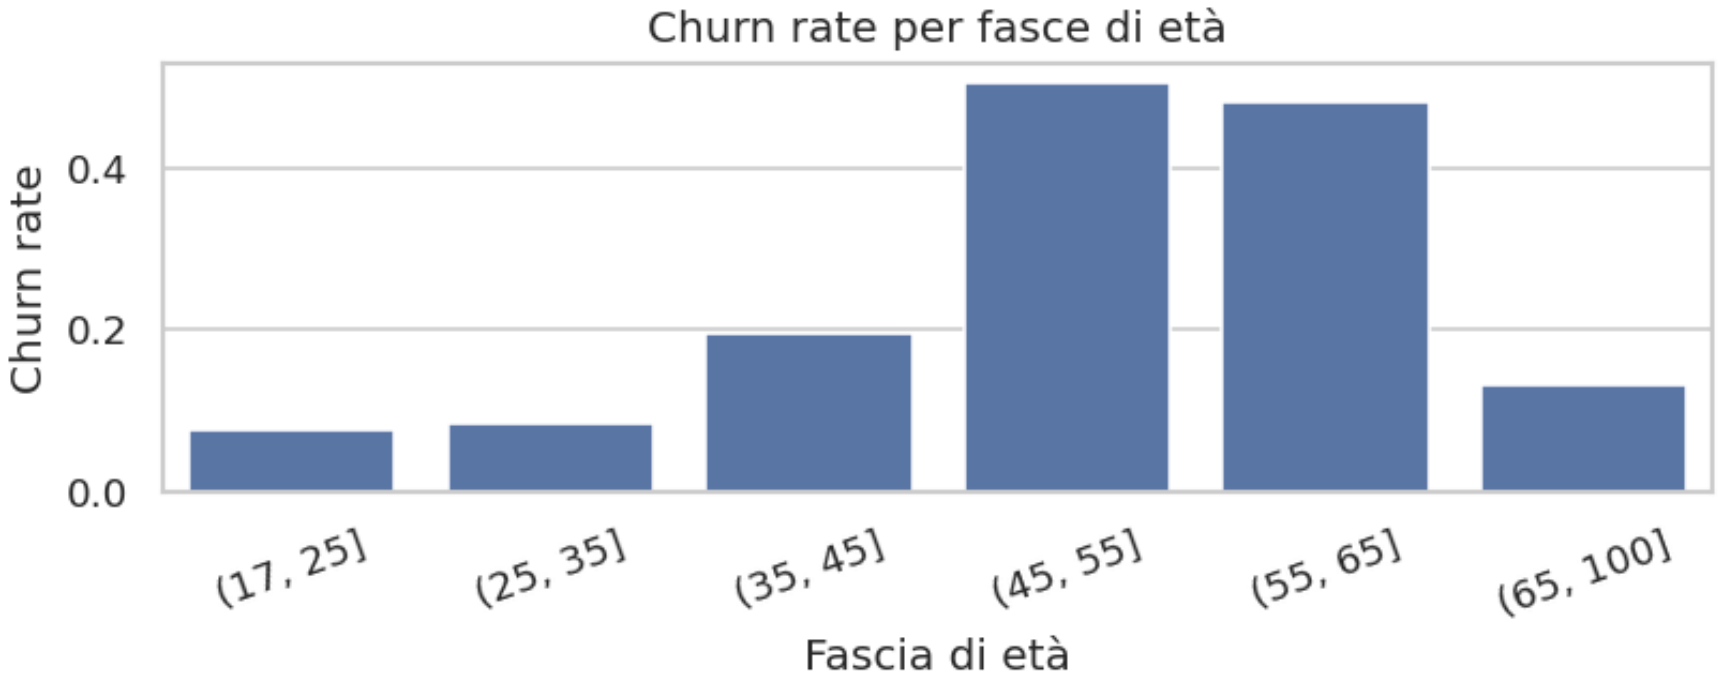

Mediana 36 anni per chi rimane, 45 per chi abbandona. Il churn sale fino al picco della fascia 46-55 anni (50.6%), poi ridiscende. Correlazione r = 0.29 — la più alta del dataset tra le feature numeriche. La relazione è non lineare: un modello lineare la sottostimerebbe.

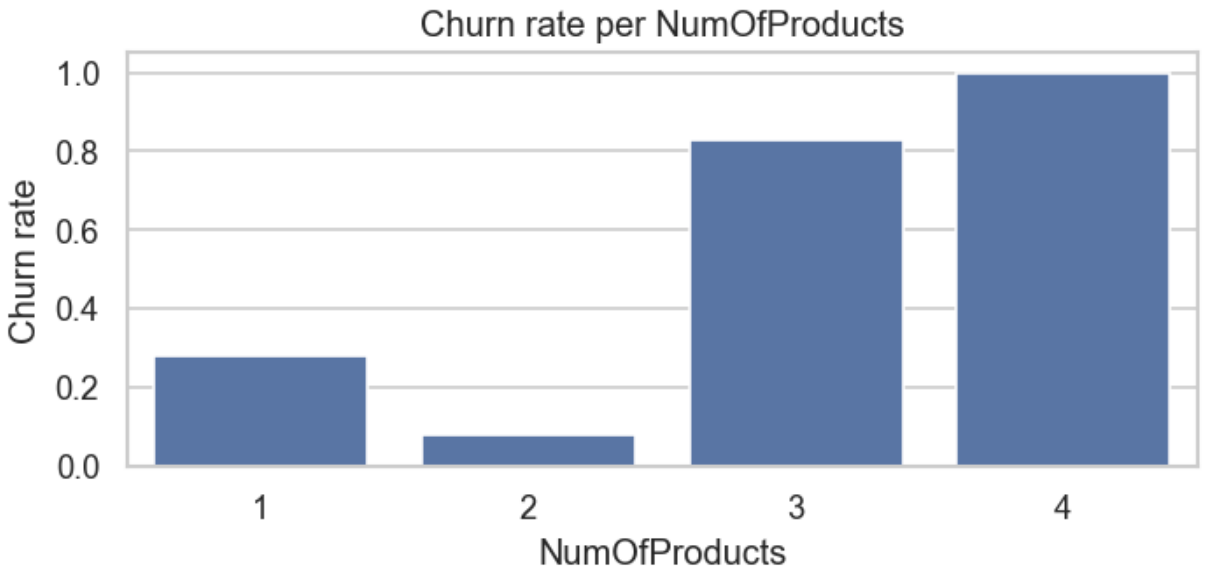
Churn rate per NumOfProducts
Churn rate
1.0
0.8
0.6
0.4
0.2
0.0
1
2
3
4
NumOfProducts

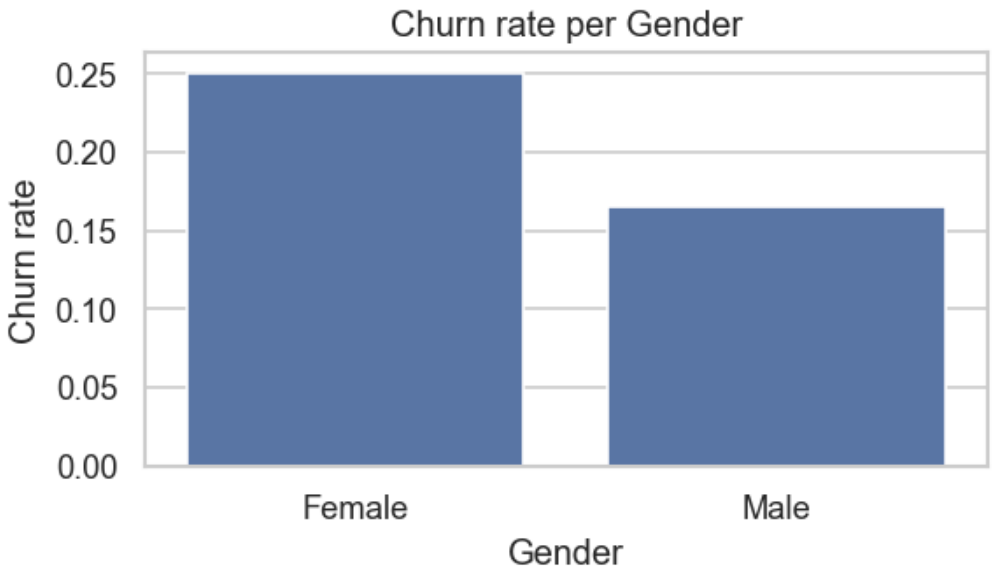
Churn rate per Gender
Churn rate
0.25
0.20
0.15
0.10
0.05
0.00
Female
Male
Gender

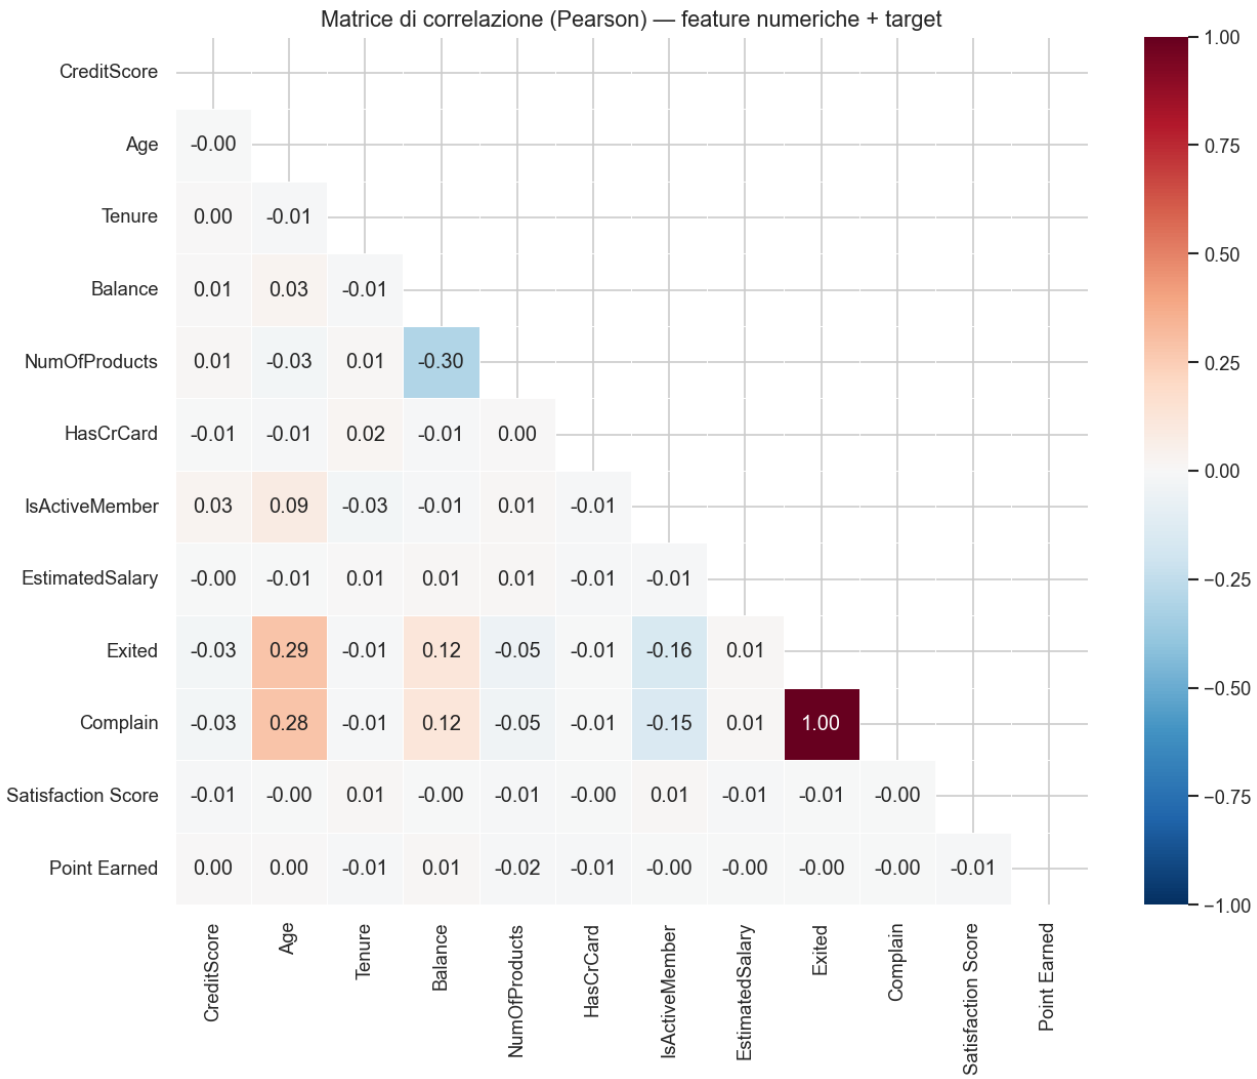

$$\rho_{x,y} = \frac{Cov(x,y)}{\sigma_x \sigma_y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

? C’è un intruso in questa matrice di correlazione

ANALISI ESPLORATIVA

"Se Complain = 1, il cliente abbandona nel 99.5% dei casi."

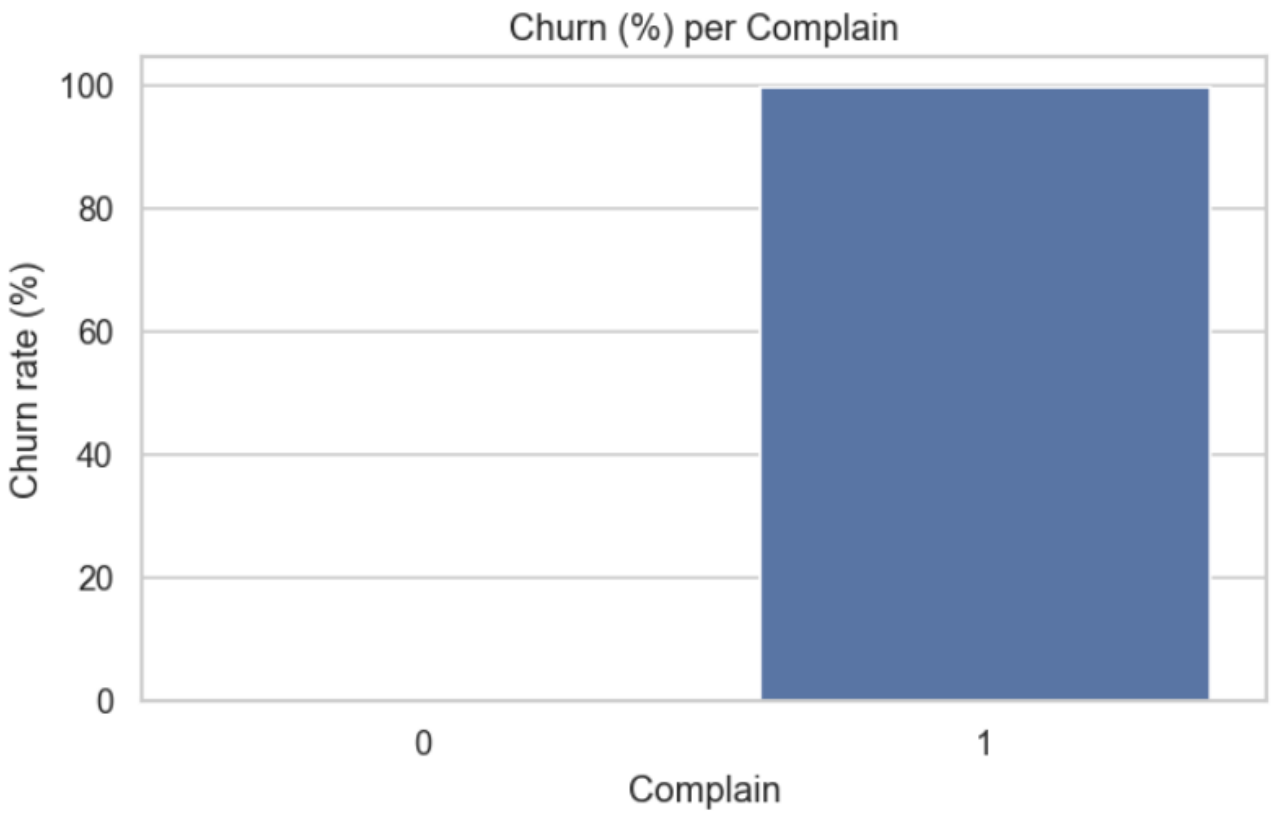

05

Live coding

Tieniti in contatto con il team

Enrico Huber

Data Scientist

+39 348 233 8245
enrico.huber@bip-group.com

Pietro Soglia

Data Scientist

+39 347 267 8420
pietro.soglia@bip-group.com

Grazie dell’attenzione