


Machine Learning per l'analisi finanziaria





+39 348 233 8245
enrico.huber@bip-group.com



+39 347 267 8420
pietro.soglia@bip-group.com



Il churn come problema di classificazione: EDA

Dal dato grezzo al dataset modellabile



Modelli di classificazione e metriche di valutazione

Feature importance e interpretabilità

Modellazione avanzata e simulazione di progetto

Agenda del corso

MACHINE LEARNING PER L'ANALISI FINANZIARIA

Modelli di classificazione e metriche di valutazione

Machine Learning per l'Analisi Finanziaria

Obiettivi della lezione

- 1 **Caricare** dataset modellabile
- 2 **Addestrare** modelli di Machine Learning
- 3 **Calcolare** metriche
- 4 **Visualizzare** Confusion Matrix e ROC
- 5 **Confrontare** modelli
- 6 **Ottimizzare** soglia di classificazione

Rollout Plan



01

Riepilogo e
caricamento
dati

Dove eravamo?

Operazione	Risultato
Rimozione variabili non predittive	RowNumber, CustomerId, Surname eliminati
Rimozione leakage	Complain ($r = 0.996$ con target) eliminato
Feature engineering	balance_is_zero creata dalla bimodalità di Balance
Encoding	<i>OneHotEncoder</i> per categoriche – 24 colonne
Scaling	<i>StandardScaler</i> per 6 feature numeriche
Split stratificato	60% train / 20% val / 20% test
Pipeline salvata	lesson_02_preprocessor.pkl

Il dataset modellabile

Split	Dimensione	Churn rate
Train	6000 x 30	20.38%
Validation	2000 x 30	20.40%
Test	2000 x 30	20.35%

6 feature numeriche scalate + 24 categoriche one-hot encoded. Zero NaN. Stratification confermata

Il baseline da superare

Insight	Baseline L1 (LogReg senza pipeline)	Obiettivo L3
ROC-AUC	0.85	> 0.85
Recall churn	37% (151/408)	> 60%
Pipeline	Fit su tutto il dataset (leakage!)	Fit solo su train

Il 37% di recall non è accettabile per un sistema di retention. Oggi faremo meglio — e in modo corretto.

02

Modelli di
classificazione

Tre famiglie, un obiettivo

Tre algoritmi, tre filosofie:
lineare, ad albero, ad
ensemble.

Stesso obiettivo: stimare
 $P(\text{Churn} = 1|X)$

Ma esiste un numero enorme di modelli di Machine Learning
con cui fare classificazione...

Modelli lineari

- Logistic Regression
- Linear Discriminant Analysis (LDA)
- Quadratic Discriminant Analysis (QDA)

Alberi e ensemble

- Decision Tree
- Random Forest
- Extra Trees
- AdaBoost
- Gradient Boosting
- XGBoost
- LightGBM
- CatBoost

Modelli basati sulla distanza e probabilistici

- k-Nearest Neighbors (k-NN)
- Naive Bayes


Kernel e reti neurali

- Support Vector Machine (SVM)
- Neural Network (MLP)

Logistic Regression – Intuizione

$$\hat{p} = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}}$$

- Combinazione lineare delle feature → singolo numero
- La **sigmoide** σ comprime il risultato tra 0 e 1 → probabilità
- Il **decision boundary** è un iperpiano nello spazio delle feature



Logistic Regression – Pro e Contro


PRO ✓	CONTRO ✗
Interpretabile (un peso per feature)	Solo decision boundary lineare
Veloce da addestrare (secondi)	Non cattura interazioni tra feature
Probabilità calibrate nativamente	Sensibile a feature non scalate
Ottima baseline di riferimento	Sottoperforma se relazioni non-lineari

Quando usarla

- Come primo modello (baseline)
- Quando l'interpretabilità è prioritaria
- Quando le feature sono ben ingegnerizzate (feature engineering compensa la linearità)

Decision Tree – Intuizione

L'albero impara una sequenza di **domande binarie** (split) che partizionano lo spazio delle feature. Ogni foglia produce una probabilità di churn.



Decision Tree – Pro e Contro


PRO ✓	CONTRO ✗
Cattura non-linearità e interazioni	Overfitting senza vincoli di profondità
Interpretabile (si disegna l'albero)	Instabile: un dato diverso → albero diverso
Non richiede feature scaling	Alta varianza (piccole perturbazioni → grandi cambiamenti)
Feature importance naturale	Prestazioni spesso inferiori agli ensemble

Dal nostro UseCase

DT senza limiti: Train AUC = **1.000**, Val AUC = **0.663** → Overfitting totale

Random Forest – Intuizione

Molti alberi diversificati votano insieme. La **decorrelazione** (bootstrap + subset di feature) riduce la varianza senza aumentare il bias.



Random Forest – Pro e Contro

PRO ✓	CONTRO ✗
Robusto a overfitting (bagging)	Meno interpretabile (200 alberi)
Cattura interazioni complesse	Più lento da addestrare
Out-of-bag error come stima interna	Molti iperparametri (n_estimators, max_depth, ...)
Feature importance integrata	Richiede più memoria

Dal nostro UseCase

RF (200 alberi): Val ROC-AUC = **0.872** — il migliore osservato

Tabella comparativa

Caratteristica	Logistic Regression	Decision Tree	Random Forest
Tipo boundary	Lineare (iperpiano)	Non-lineare (assi paralleli)	Non-lineare (ensemble)
Gestisce non-linearità	X (solo con feature eng.)	✓	✓
Interpretabilità	Alta (pesi)	Media (albero visualizzabile)	Bassa (black-box)
Rischio overfitting	Basso	Alto (senza vincoli)	Medio (bagging regolarizza)
Richiede scaling	Sì	No	No

03

Metriche di
valutazione

L'importanza delle metriche

Un modello senza metriche è un'opinione. E un modello
con la metrica sbagliata è un'illusione




Metriche per problemi di classificazione

Reminder della lezione 2

Metrica	Formula	Quando usarla
Accuracy	$\frac{t_p + t_n}{t_p + t_n + f_p + f_n}$	Metrica di default, non adatta per classi sbilanciate
Precision	$\frac{t_p}{t_p + f_p}$	Alta precisione → meno falsi positivi
Recall	$\frac{t_p}{t_p + f_n}$	Alta recall → meno falsi negativi
F1-score	$2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$	Media armonica di precision e recall

ROC-AUC Curve



04

Confronto
tra modelli


Risultati su Validation Set

Modello	Accuracy	Precision	Recall	F1	ROC-AUC
Dummy (sempre «non churn»)	0.796	0.000	0.000	0.000	0.500
LR (<i>class_weight</i>)	0.779	0.475	0.784	0.591	0.855
DT (depth=6, cw)	0.775	0.469	0.777	0.585	0.843
RF (soglia=0.5)	0.859	0.778	0.429	0.553	0.872
RF (soglia=0.36)	0.865	0.685	0.623	0.652	0.872


Nessun modello domina su tutte le metriche

RF ha la migliore AUC (0.872), ma la soglia 0.5 sacrifica il recall. Con soglia ottimale (0.36):
F1 = 0.652, il miglior compromesso.

Confusion Matrix a confronto



Curve ROC a confronto





Nessun vincitore universale

Scenario	Obiettivo	Modello consigliato	Soglia	Risultato atteso
Budget illimitato – Contattare tutti i potenziali cherner	Massimizzare recall	LR <i>class_weight</i>	0.5	Recall 78%, 320/408 salvati
Budget limitato – Solo interventi mirati con alta probabilità	Massimizzare Precision	RF	Soglia alta (0.5+)	Precision 70%+, pochi falsi allarmi
Compromesso – Bilanciare copertura e budget	Massimizzare F1	RF	0.36	F1 0.652, miglior compromesso

Non esiste il modello migliore in assoluto.
Esiste il modello migliore per il vostro
obiettivo di business

Trade-off Precision-Recall per RF



03

IL CHURN COME PROBLEMA DI CLASSIFICAZIONE



05

Live coding

Tieniti in contatto con il team



Enrico Huber

Data Scientist

+39 348 233 8245
enrico.huber@bip-group.com



Pietro Soglia

Data Scientist

+39 347 267 8420
pietro.soglia@bip-group.com



Grazie dell'attenzione