


Machine Learning per l'analisi finanziaria





+39 348 233 8245
enrico.huber@bip-group.com



+39 347 267 8420
pietro.soglia@bip-group.com



Il churn come problema di classificazione: EDA

Dal dato grezzo al dataset modellabile

Modelli di classificazione e metriche di valutazione

 Feature importance e interpretabilità

Modellazione avanzata e simulazione di progetto

Agenda del corso

MACHINE LEARNING PER L'ANALISI FINANZIARIA

Modelli di classificazione e metriche di valutazione

Machine Learning per l'Analisi Finanziaria

Obiettivi della lezione

1	Feature Importance
---	---------------------------

2	SHAP
---	-------------

3	Waterfall
---	------------------

4	Feature Selection
---	--------------------------

5	Fairness
---	-----------------

6	Normativa
---	------------------

Rollout Plan



01

Setup e
riepilogo

Dove eravamo — Riepilogo Lezione 3

Il punto di partenza per oggi

Modello selezionato: **RandomForestClassifier** (n_estimators=200, class_weight='balanced')

Threshold ottimizzato: **0.36** (massimizza F1 su validation set)

Val ROC-AUC: **0.8723** | Test ROC-AUC: **0.8575**


Test F1: **0.6055** | Test Recall: **0.5921** | Test Precision: **0.6195**

Artefatti salvati: *lesson_03_best_model.pkl* *lesson_03_metrics.json*

```
{
  "best_model": "RandomForestClassifier(n_estimators=200, class_weight='balanced',
random_state=42)",
  "best_threshold": 0.36,
  "train": {
    "accuracy": 1.0,
    "precision": 1.0,
    "recall": 1.0,
    "f1": 1.0,
    "roc_auc": 1.0
  },
  "val": {
    "accuracy": 0.8645,
    "precision": 0.6846,
    "recall": 0.6225,
    "f1": 0.6521,
    "roc_auc": 0.8723
  },
  "test": {
    "accuracy": 0.843,
    "precision": 0.6195,
    "recall": 0.5921,
    "f1": 0.6055,
    "roc_auc": 0.8575
  }
}
```


Il modello che interpretiamo oggi

Caricato da lesson_03_best_model.pkl — nessun re-training



Domanda motrice

Dall'accuratezza alla comprensione

«Un modello che non si capisce non si può migliorare ne' spiegare al cliente.»

AUC = **0.86** è un ottimo risultato.

Ma se il cliente chiede *‘perché sono a rischio churn?’* — cosa rispondiamo?

Se il regolatore chiede *‘come decide il modello?’* — siamo pronti?

02

Feature
importance

"Quali feature contano? Dipende da come chiedi."

3 metodi diversi — 3 risposte diverse

Quanto ogni feature
riduce l'impurità negli
split del Random
Forest?

Gini Importance (MDI)

Quanto degrada la
predizione se la
feature viene shuffled?

Permutation importance

Qual è il contributo
esatto di ogni feature alla
singola predizione

SHAP

Gini Importance — Mean Decrease Impurity

Calcolata internamente dal RF durante il training

$$Gini = 1 - \sum_{i=1}^C (p_i)^2$$

Top-3 dal modello:


Rank 1: Age (MDI $\approx$ 0.195)

Rank 2: Point Earned

Rank 3: EstimatedSalary

Vantaggio: gratuita, zero costo aggiuntivo

Limite: bias verso feature continue ad alta cardinalita'



Permutation Importance — Val Set (30 ripetizioni)

Misura il reale impatto out-of-sample

Passo 1: Calcola AUC sul val set con le feature originali

Passo 2: Per ogni feature j: shuffle i valori → ricalcola AUC

Passo 3: $\text{Importance}(j) = \text{AUC}_{\text{originale}} - \text{AUC}_{\text{shuffled}(j)}$


Top-3 dal modello:

Rank 1: NumOfProducts_2 ($\Delta\text{AUC} \approx 0.115$)

Rank 2: Age ($\Delta\text{AUC} \approx 0.112$)


Rank 3: NumOfProducts_1

Calcolata post-training: misura impatto reale, non bias da split interni



Gini vs Permutation — Convergenza e divergenze

Top-5 concordano; le divergenze nel tail rivelano correlazioni nascoste



Gini vs Permutation — Convergenza e divergenze

Top-5 concordano; le divergenze nel tail rivelano correlazioni nascoste

Age: Gini rank 1 | Perm rank 2 → CONVERGENZA

NumOfProducts_2: Gini rank 6 | Perm rank 1 → Concordi

Balance: Gini rank 5 | Perm rank 5 → Concordi

Tenure: Gini rank 7 | Perm rank 28 → DIVERGENZA forte

CreditScore: Gini rank 4 | Perm rank 25 → DIVERGENZA —
correlato con altri

EstimatedSalary: Gini rank 3 | Perm rank 15 → Divergenza moderata

Divergenze = segnali di correlazione tra feature o importanza
condizionata

03

SHAP e
spiegabilità
globale

SHAP: dal ranking al contributo

Basato sulla teoria di Shapley dei giochi cooperativi

Formula additiva: $\hat{p}(x) = \phi_0 + \sum \phi_j(x)$

$\hat{p}(x)$ = probabilita' di churn predetta per il cliente x

ϕ_0 = baseline = probabilita' media di churn ≈ 0.204

$\phi_j(x)$ = contributo SHAP della feature j per questo cliente

Segno del contributo:

$\phi_j > 0 \rightarrow$ spinge verso churn

$\phi_j < 0 \rightarrow$ protegge dal churn

Come funziona: dal baseline alla predizione

Ogni feature riceve il suo contributo marginale medio

Baseline: prob = 0.204 (churn medio del dataset)

+ Age alta: +0.12 (spinge verso churn)

+ NumOfProducts basso: +0.08 (spinge verso churn)

+ IsActiveMember = 0: +0.06 (spinge verso churn)

+ Geography = Germany: +0.03 (spinge verso churn)

- IsActiveMember = 1: -0.05 (protegge dal churn)

+ ...altri 25 contributi...

Predizione finale: ≈ 0.72

SHAP Summary Plot — Importanza e direzione

Ogni punto = una predizione | Colore = valore feature (rosso=alto, blu=basso)

Come leggere:

Asse Y: feature ordinate per mean |SHAP| — in alto le più importanti


Asse X: valore SHAP (neg = protegge, pos = aumenta rischio churn)

Lettura top-3:

Age alta (rosso) → punti a destra → forte rischio churn

NumOfProducts_2 assente → impatto positivo importante sul churn

Geography=Germany → rischio residuo aggiuntivo per clienti tedeschi



Top-10 feature — Consensus da 3 metodi

lesson_04_feature_ranking.json | n=30 feature

Colonna	Ranking GINI	Ranking Permutazioni	Ranking SHAP
Age	Gini 1	Perm 2	SHAP 1 ★★★
NumOfProducts_2	Gini 6	Perm 1	SHAP 2 ★★★
Balance	Gini 5	Perm 5	SHAP 3 ★★★
Geography_Germany	Gini 10	Perm 4	SHAP 4 ★★
IsActiveMember_1	Gini 11	Perm 7	SHAP 5 ★★
Point Earned	Gini 2	Perm 9	SHAP 6 ★★
CreditScore	Gini 4	Perm 25	SHAP 7 ★
EstimatedSalary	Gini 3	Perm 15	SHAP 8 ★

04

Interpretabilità
locale

Da globale a locale: il waterfall plot SHAP

La spiegazione per singolo cliente — dal baseline alla predizione finale

$E[f(x)] = 0.204$ (baseline = churn medio del dataset)

+ Age alta: +0.12 (cliente anziano → rischio churn)

+ Pochi prodotti: +0.08 (pochi prodotti → rischio churn)

+ Inattivo: +0.06 (bassa engagement → rischio churn)

- Cliente attivo: -0.05 (engagement alta → protegge)

...altri 25 contributi...

$f(x) = 0.72$ (predizione finale per questo cliente)

Churner ad alta confidenza — $P(\text{churn}) = 0.815$

Predizione corretta — tutti i driver convergono verso churn

NumOfProducts_3: +0.20 (3 prodotti — profilo anomalo)

NumOfProducts_2: +0.12 (assenza prodotto 2)


Age: +0.12 (cliente relativamente anziano)

NumOfProducts_1: +0.07 (segnale prodotti coerente)

Balance: -0.04 (saldo sotto la media — fattore protettivo)

Tutti i principali driver puntano nella stessa direzione.

Il modello è molto sicuro — e ha ragione.



Non-churner ad alta confidenza — $P(\text{churn}) = 0.070$

Predizione corretta — fattori protettivi dominanti

NumOfProducts_2: -0.14 (ha il prodotto 2 — fattore protettivo forte)

Age: +0.12 (età elevata — unico driver di rischio)


IsActiveMember_1: -0.07 (cliente molto attivo)

IsActiveMember_0: -0.05 (coerenza inattività)

Balance: -0.04 (saldo nella norma)

Il profilo opposto al churner: prodotti attivi, alta engagement.

Ogni fattore spinge verso 'rimane'.



Caso borderline — $P(\text{churn}) = 0.525$

Forze contrapposte — soglia 0.36 → classificato come Churn

Age: +0.12 eta' spinge verso churn

NumOfProducts_2: +0.08 assenza prodotto 2 → rischio


Geography_Germany: -0.06 non e' tedesco → fattore protettivo

Balance: -0.03 saldo nella media

Il cliente piu' difficile da classificare:

segnali forti in entrambe le direzioni.

Con soglia = 0.36: classificato A RISCHIO — scelta deliberata per massimizzare il recall.



Falso negativo — pred=0.175, realta': ha fatto churn

SHAP spiega anche i fallimenti del modello

Probabilita' predetta: 0.175 (sotto soglia 0.36)

Classificazione: Non-Churner X ERRORE


Realta': Ha fatto churn

Age: -0.23 eta' bassa — il principale segnale PROTEGGE

Il profilo sembrava 'sicuro' secondo tutte le 30 feature del dataset.

Il churn e' avvenuto per ragioni non catturate dal modello.

Lezione: il modello e' buono quanto i dati che ha.



Profilo medio del churner — SHAP aggregato su 203 churner reali

lesson_04_risk_profile.json

Age: SHAP +0.068 — clienti mediamente più anziani

NumOfProducts_2: SHAP +0.061 — pochi prodotti attivi


Geography_Germany: SHAP +0.030 — concentrazione geografica in Germania

NumOfProducts_1: SHAP +0.022 — segnale prodotti coerente

IsActiveMember_1: SHAP +0.019 — bassa engagement

Profilo tipo: anziano, pochi prodotti, tedesco, inattivo.

Informazione azionabile per la strategia di retention.



04

IL CHURN COME PROBLEMA DI CLASSIFICAZIONE



05

Feature
selection

Ipotesi: bastano i top-K feature?

Ciclo scientifico: Ipotesi → Esperimento → Osservazione → Decisione

Ipotesi: Le feature con rank SHAP basso aggiungono rumore, non signal

Esperimento: Re-training RF con top-K feature (K = 10, 15, 20, 30)

Misura: ROC-AUC su val set e test set per ogni K

Decisione: Scegliere K minimo che mantiene AUC entro tolleranza accettabile

K=10: top-10 SHAP → Ipotesi sweet spot

K=15: top-15 SHAP → Intermedio

K=20: top-20 SHAP → Quasi completo

K=30: tutte le feature → Baseline (AUC=0.8723)

Curva AUC al variare del numero di feature

Plateau evidente: il guadagno oltre K=15 e' marginale

K=10: AUC val ≈ 0.861 | Delta vs K=30: -0.011


K=15: AUC val ≈ 0.868 | Delta vs K=30: -0.004 ← **SWEET SPOT**

K=20: AUC val ≈ 0.866 | Delta vs K=30: -0.006

K=30: AUC val = 0.872 | Baseline completo

Con 15 feature su 30, il modello perde meno dello 0.5% di AUC.

Le feature 16-30 portano guadagni marginali a fronte di maggiore complessità.



Trade-off: semplicita' vs accuratezza

Raccomandazione: top-15 feature in produzione

K=5: AUC 0.861 Recall cala Spiegabilita': ★★★★★ (5 fattori)

K=10: AUC 0.861 Recall cala Spiegabilita': ★★★★★

K=15: AUC 0.868 Recall OK Spiegabilita': ★★★ ← RACCOMANDATO

K=30: AUC 0.872 Baseline Spiegabilita': ★★ (30 fattori impraticabili)

Top-15 in produzione: ottimo equilibrio tra accuratezza (AUC=0.868),

recall stabile e spiegabilità concreta al cliente.

Perdita di soli 0.4 punti AUC in cambio di un modello mantenibile e comunicabile.

L'interpretabilità come obbligo normativo

Non è una scelta: è un requisito legale

GDPR Art.22:

Il cliente ha diritto a non essere soggetto a decisioni automatizzate
senza una spiegazione significativa e comprensibile

EBA ML Guidelines — Sez. 4.2:

I modelli ML in ambito bancario devono essere documentati,
validati e spiegabili al management e ai regolatori

EU AI Act Art.13:

I sistemi AI ad alto rischio (credito, scoring, churn bancario)
devono fornire output interpretabili, tracciabili e auditabili

Feature sensibili e rischio fairness


Gender e Geography: impatto quantificabile con SHAP

Feature	SHAP	Caratteristica	Rischio
Age	0.068	Comportamentale	BASSO ✓
NumOfProducts_2	0.061	Comportamentale	BASSO ✓
Geography_Germany	0.030	Geografica/proxy	MEDIO ⚠
Gender_Female	0.014	Demografica	ALTO X

Raccomandazione: keep + audit trimestrale

Monitorare disparate impact (ratio AUC uomini / AUC donne) ogni trimestre.

Il modello usa Gender. Il rischio esiste — monitoriamolo.



04

IL CHURN COME PROBLEMA DI CLASSIFICAZIONE



06

Live coding

Tieniti in contatto con il team



Enrico Huber

Data Scientist

+39 348 233 8245
enrico.huber@bip-group.com



Pietro Soglia

Data Scientist

+39 347 267 8420
pietro.soglia@bip-group.com



Grazie dell'attenzione